

# Fila Dinámica — Informe de Ingeniería

Análisis del sistema de asignación de clientes en tiempo real · teoría de colas, cadenas de Markov y validación Monte Carlo sobre datos de producción · 2026-05-16

## 1 · Resumen ejecutivo

La barbería es, formalmente, un **sistema de colas multi-servidor**: los clientes walk-in llegan según un proceso de **Poisson** de tasa variable  $\lambda(t)$ , y cada barbero es un servidor con tasa media de servicio  $\mu$ . Este informe demuestra —con teoría y con datos reales— que el modelo actual (**pool dinámico no bloqueante**, mig 134) es la arquitectura **correcta y óptima** para este problema, y cuantifica por qué el modelo anterior (binding pegajoso) era subóptimo.

35.0 min

Tiempo medio de servicio

$\mu = 1.71$  cortes/h/barbero

0.93

Índice de dispersión

$\approx 1 \Rightarrow$  Llegadas Poisson (validado)

0.99

Índice de Jain (equidad)

barberos activos · 1.00 = perfecto

0.00 min

Inanición con el pool

vs 20–71 min/turno con el binding

**Conclusión.** Con un único pool (M/M/c) el sistema es **trabajo-conservativo** y alcanza el óptimo teórico de espera. El diseño anterior equivalía a **c filas independientes ( $c \times M/M/1$ )**, que el teorema de pooling demuestra estrictamente peor: hasta **16x** más espera y barberos ociosos con clientes esperando en el 71–98 % de los turnos. Y no es un caso de borde:  **$\approx$  la mitad o más** de los walk-ins eligen "menor espera" (§8) — el diseño anterior degradaba a la **mayoría** de los clientes.

## 2 · El modelo formal

Usamos la notación de Kendall **A/B/c**: distribución de llegadas / distribución de servicio / número de servidores. La barbería es un **M/G/c**:

- **M** (Markoviano) — llegadas Poisson, tiempos entre llegadas exponenciales y *sin memoria*. Validado en §3 (índice de dispersión 0.93).
- **G** (General) — el servicio **no** es exponencial: es **log-normal** con  $CV = 0.39 \ll 1$ , mucho más *regular* que la exponencial (§4).
- **c** servidores — los barberos disponibles (típico 4.9 en Rondeau, 5.8 en Paraná).

Un cliente **específico** (elige barbero) crea su propia mini-cola hacia ese servidor. Un cliente **dinámico** ("menor espera") entra a un **pool compartido** que alimenta a los **c** servidores: ese es exactamente un **M/G/c**. El cambio de mig 134 fue pasar de "c colas M/G/1 separadas" a "una cola M/G/c". La §6 prueba por qué eso importa.

```
Variables ·  $\lambda$  = tasa de llegada (clientes/h) ·  $\mu$  = 1.714 servicios/h/barbero (= 60/35.0)
a =  $\lambda/\mu$  (carga ofrecida, Erlangs) ·  $\rho$  =  $a/c = \lambda/(c \cdot \mu)$  (utilización) · estable  $\Leftrightarrow \rho < 1$ 
```

### 3 · Proceso de llegadas — validación de Poisson

Un proceso de Poisson tiene dos firmas comprobables en los datos: (1) el número de llegadas en intervalos fijos tiene **varianza = media** (índice de dispersión = 1), y (2) los tiempos entre llegadas son **exponenciales** (coeficiente de variación = 1). Medido sobre Rondeau, ventana operativa 10–20 h, 821 buckets de 30 min:

**2.42**

Media llegadas /30 min

**2.25**

Varianza /30 min

**0.93**

Índice de dispersión

Var/Media — Poisson = 1.00


**1.23**

CV inter-arribos

Exponencial = 1.00


**Resultado.** Índice de dispersión 0.93 y CV de inter-arribos 1.23: ambos  $\approx 1$ . Las llegadas son un **proceso de Poisson**, con la salvedad de que  $\lambda$  **varía con la hora** (Poisson *no homogéneo*): el modelo M/M/c se aplica por tramos horarios, no con un  $\lambda$  único.

Perfil real de  $\lambda(t)$  — llegadas por hora, 60 días. El pico es ~18 h en ambas sucursales (Paraná 6.88/h, Rondeau 5.69/h):



## 4 · Proceso de servicio


Sobre 5,272 cortes (90 días): media **35.01 min**, desvío 13.67, **CV = 0.39**. Ajusta una **log-normal** ( $\mu_{\log} = 3.4827$ ,  $\sigma_{\log} = 0.3915$ ); la curva ajustada cae exactamente sobre los percentiles observados:



**Implicación teórica clave.** Como  $CV_s = 0.39 < 1$ , el servicio es **más regular que una exponencial** ( $CV=1$ ). Por la aproximación de **Allen-Cunneen** para G/G/c, la espera real es  $(C_a^2 + C_s^2)/2 = 0.58\times$  la que predice M/M/c. Es decir: el sistema real espera **~42 % menos** que el peor caso markoviano. Las predicciones de §5–§6 incluyen esta corrección.

### Varianza por tipo de servicio


El tiempo depende fuertemente del servicio (Barba ~23 min vs Corte+Barba ~43 min). Un promedio único es un mal predictor — esto fundamenta la mejora de §9.



| Servicio             | n    | Media    | Desvío | Mediana  |
|----------------------|------|----------|--------|----------|
| Corte                | 3073 | 32.7 min | ±11.2  | 31.6 min |
| Corte (var.)         | 1774 | 38.0 min | ±15.6  | 36.2 min |
| Corte y Barba        | 177  | 41.6 min | ±12.9  | 40.2 min |
| Corte + Barba        | 126  | 43.3 min | ±17.2  | 43.3 min |
| Corte + Barba (var.) | 59   | 34.8 min | ±10.6  | 32.7 min |
| Barba                | 40   | 22.6 min | ±15.6  | 18.5 min |


## 5 · Cadena de Markov y condición de estabilidad

El número de clientes en el sistema es una **cadena de Markov de tiempo continuo** de tipo **nacimiento-muerte**. Por la propiedad *sin memoria* de las llegadas Poisson y los servicios markovianos, el estado futuro depende solo del estado actual:



Proceso de nacimiento-muerte · nacimientos  $\lambda$  (Poisson) · muertes  $n \cdot \mu$  ( $n \leq c$ ) y  $c \cdot \mu$  ( $n > c$ )

La distribución estacionaria  $\pi_n$  (probabilidad de tener  $n$  clientes) es la solución de equilibrio de flujo (**Erlang**). Para el escenario Rondeau-pico ( $a = \lambda/\mu = 3.32$ ,  $c = 5$ ,  $\rho = 66\%$ ):



**Estabilidad.** El sistema es estable si y solo si  $\rho = \lambda/(c \cdot \mu) < 1$  (los servidores pueden drenar la cola más rápido de lo que llega). Rondeau-pico:  $\rho = 66\% < 1$  ✓ — cola finita y estacionaria. Si  $\rho \rightarrow 1$  la espera crece sin techo (no lineal): por eso la capacidad ( $c$ ) debe seguir a  $\lambda(t)$  en horas pico.


De  $\pi_n$  se derivan, vía **Ley de Little ( $L = \lambda \cdot W$ )**, todas las métricas operativas. Verificación con datos reales de Rondeau (día completo):  $\lambda \approx 3.97/h$ ,  $W$  observado  $\approx 57$  min  $\Rightarrow L = \lambda \cdot W \approx 3.8$  clientes en el sistema en promedio — consistente con 4.9 barberos a utilización

media.

## 6 · Por qué el pool es la arquitectura correcta

Éste es el corazón del informe. **Teorema (pooling / "single queue")**: una única cola M/M/c con tasa total  $\lambda$  es **siempre** mejor (menor espera media) que c colas M/M/1 independientes con  $\lambda/c$  cada una. Razón: una sola cola es **trabajo-conservativa** — ningún servidor está ocioso si hay alguien esperando. c colas separadas **no** lo son: un servidor puede estar libre mientras otro acumula cola.

El binding pegajoso (mig 132/133) ataba cada dinámico a un barbero **en el check-in**: de facto, c colas M/M/1. El pool (mig 134) asigna **cuando el barbero se libera**: una cola M/M/c. Cuantificado con los parámetros reales ( $\mu=1.71/h$ ):




| Escenario                  | Pool M/M/c (Wq) | Pool real G/G/c | c × M/M/1 (binding) | Penalización |
|----------------------------|-----------------|-----------------|---------------------|--------------|
| Rondeau pico (λ=5.69, c=5) | 6.7 min         | 3.9 min         | 69 min              | 10.3×        |
| Paraná pico (λ=6.88, c=6)  | 5.1 min         | 2.9 min         | 71 min              | 13.9×        |
| c=10, ρ=0.85               | 12.4 min        | 7.1 min         | 198 min             | 16.0×        |

**Hallazgo.** Con el binding, en hora pico la espera teórica se multiplica por **10–16×** y aparecen estados imposibles bajo M/M/c: barbero ocioso + cliente esperando. La Monte Carlo (§7) confirma esto empíricamente sobre 43 200 turnos simulados.

### Curva de Erlang-C (la "pared" de la congestión)

Wq crece de forma **no lineal** con  $\rho$  — es estable hasta ~80 % y explota cerca de 1. Los puntos negros son los regímenes reales medidos. Línea verde = espera real corregida por la regularidad del servicio (Allen-Cunneen).






| Escenario real         | $\lambda/h$ | c | a (Erlang) | $\rho$ | P(esperar) | $W_q$ M/M/c | $W_q$ real G/G/c | W (con servicio) |
|------------------------|-------------|---|------------|--------|------------|-------------|------------------|------------------|
| Rondeau · pico 18 h    | 5.69        | 5 | 3.32       | 66%    | 0.32       | 6.7         | 3.9              | 41.7             |
| Rondeau · promedio día | 3.97        | 5 | 2.32       | 46%    | 0.10       | 1.3         | 0.8              | 36.3             |
| Paraná · pico 18 h     | 6.88        | 6 | 4.01       | 67%    | 0.29       | 5.1         | 2.9              | 40.1             |
| Paraná · promedio día  | 5.33        | 6 | 3.11       | 52%    | 0.11       | 1.4         | 0.8              | 36.4             |
| Caseros · promedio día | 1.71        | 2 | 1.00       | 50%    | 0.33       | 11.6        | 6.7              | 46.6             |

## 7 · Simulación Monte Carlo

Modelo de eventos discretos calibrado con los datos reales (servicio log-normal  $\mu_{\log}=3.4827$ ,  $\sigma_{\log}=0.3915$ ). Grilla: barberos {3,5,7,10} × carga {0.8, 1.0, 1.15} × % dinámico {25,50,80} × popularidad {uniforme, estrella} × 5 políticas × 120 réplicas = **43 200 turnos simulados**. Reproducible en `docs/sim/fila_montecarlo.py`.


Políticas: **A** binding pegajoso (modelo viejo) · **B** binding con push instantáneo · **C** pool no bloqueante (modelo live, mig 134) · **D** pool + WSJF · **E** pool con gate de equidad.

### El invariante duro: ningún barbero ocioso con un dinámico esperando



**A ≈ B.** Quitar el "push-on-complete" casi no cambia nada (la barra A ≈ B): el problema **no** era el push, era el **binding**. **C = D = 0.00**: el pool lo elimina de raíz. **E** (gate de equidad bloqueante) *reintrodujo* el problema — confirmó numéricamente que la equidad nunca debe retener trabajo.

### Eficiencia y experiencia (selección de métrica)



| Escenario   | Inanición A→C (min/turno) | Utilización A→C | Espera P50 A→C→D (min) | Jain A / C    |
|-------------|---------------------------|-----------------|------------------------|---------------|
| 3 barberos  | 19.5 → 0.00               | 78.8% → 81.0%   | 56 → 47 → 31           | 0.983 / 0.975 |
| 5 barberos  | 38.1 → 0.00               | 79.6% → 81.9%   | 50 → 40 → 28           | 0.966 / 0.956 |
| 7 barberos  | 54.8 → 0.00               | 79.7% → 82.0%   | 45 → 35 → 25           | 0.951 / 0.940 |
| 10 barberos | 70.8 → 0.00               | 79.5% → 81.7%   | 41 → 32 → 24           | 0.928 / 0.915 |

Throughput idéntico entre políticas a estas cargas (el turno satura): el daño del binding no es "menos cortes" sino espera, ociosidad con cola, y la promesa rota de "menor espera". El pool además sube utilización ~2 pp (≈ 0.2 barbero recuperado con 10 sillas).

## 8 · Auditoría de datos y patrones

### Espera real por sucursal (60 días)

| Sucursal | n    | Media    | P50      | P90      | P95      |
|----------|------|----------|----------|----------|----------|
| Parana   | 2591 | 18.7 min | 9.4 min  | 48.4 min | 60.1 min |
| Rondeau  | 1904 | 21.7 min | 13.8 min | 52.8 min | 67.0 min |
| Caseros  | 768  | 17.7 min | 5.4 min  | 51.1 min | 68.2 min |

Las esperas reales (Rondeau P50 13.8 / Paraná P50 9.4 min) son del orden que predice el modelo G/G/c corregido para carga media — el modelo **explica los datos**. Las colas P90/P95 (~50–67 min) corresponden a los picos de 17–19 h, donde  $p \rightarrow 0.8$ .

### Operación por sucursal

| Sucursal | Entries/día | Barberos/día | % cancelado | % completado |
|----------|-------------|--------------|-------------|--------------|
| Parana   | 53.3        | 5.8          | 3.1%        | 96.8%        |
| Rondeau  | 39.7        | 4.9          | 4.5%        | 95.3%        |
| Caseros  | 17.1        | 2.0          | 2.7%        | 96.8%        |

### Adopción real de "menor espera" — corrección metodológica

**Corrección.** Una versión preliminar reportó adopción de "menor espera" de 0.6–2.3 %. **Es incorrecto.** `claim_next_for_barber` hace `SET is_dynamic=false` al asignar al cliente: las entries completed (95–96 % del total) pierden la marca. Medir `is_dynamic` sobre el histórico mide ruido (dinámicos que se cancelaron), no adopción.

El único subconjunto donde la marca **sobrevive** (entries **canceladas**, nunca reclamadas) muestra la realidad:

| Sucursal | Cancelados (n) | Dinámicos | % dinámico (marca intacta) |
|----------|----------------|-----------|----------------------------|
| Parana   | 82             | 40        | 48.8%                      |
| Rondeau  | 90             | 46        | 51.1%                      |
| Caseros  | 21             | 5         | 23.8%                      |

**Lectura correcta.**  $\approx 47\%$  de los walk-ins eligen "menor espera" (Paraná 48.8 %, Rondeau 51.1 %) — **la mayoría**, consistente con la operación diaria. Es una **cota inferior**: los dinámicos esperan menos  $\Rightarrow$  cancelan menos  $\Rightarrow$  están sub-representados entre los cancelados; la adopción real es probablemente mayor. **Implicación:** el binding pegajoso (mig 132/133) degradaba a **~la mitad o más** de los clientes, no a un nicho del 2 % — multiplica el valor del fix mig 134 (§6) y **refuerza** la tesis del informe.

## Demanda por día y hora — Rondeau



## Equidad de carga — Rondeau (30 d)



Jain entre los 5 barberos activos = **0.990** ( $\approx$  perfecto). El sistema reparte equitativamente; Rodri/Tony bajos = part-time/ocultos, no inequidad.

**Patrones detectados.** **(1)** "Menor espera" es la elección **mayoritaria** ( $\approx 47\%+$ , ver corrección arriba): el modelo pool gobierna la experiencia de la mayoría de los clientes, no la de un nicho. **(2)** Abandono bajo (cancelado 3–4.5 %): los clientes esperan en vez de irse  $\rightarrow$  la espera es un costo real de experiencia, no de ingresos perdidos (aún). **(3)** Demanda muy concentrada Jue–Sáb 17–19 h: la capacidad (c) debería escalar por franja, no ser plana. **(4)** Higiene de datos: servicios duplicados por espacios ("Corte" vs "Corte ") — distorsiona analítica por servicio; normalizar. **(5) Brecha de modelo de datos:** la modalidad de check-in no se persiste (`is_dynamic` se muta al asignar). Imposible medir adopción o segmentar el histórico por modalidad — ver §9.

---

## 9 · Mejoras notables (Phase 2)

Priorizadas por impacto/esfuerzo, todas *sobre* el pool (nunca contra él):

1. **Predicción de duración por (barbero, servicio).** Hoy el panel usa un fallback de 25 min; los datos muestran 23→43 min según servicio. Una vista materializada precalculada por cron (no por tick — ver incidente 30/04) mejora el ETA y habilita lo siguiente. Impacto: estimación de espera fiable, base para WSJF.
2. **WSJF acotado por aging** en el claim del pool (política D): la Monte Carlo muestra **P50 –40 %** sin sacrificar el invariante. Como término aditivo del score, nunca como gate (lección de E / mig 129).
3. **Capacidad dinámica por franja.**  $p \rightarrow 0.8$  sólo Jue–Sáb 17–19 h. Sugerir refuerzo en esas 6 franjas reduce el P95 sin contratar a tiempo completo.
4. **Columna inmutable de modalidad de check-in** (p. ej. `chose_dynamic`, fijada en el INSERT y nunca mutada). Hoy `is_dynamic` se resetea al asignar → imposible medir adopción, ETA por modalidad o segmentar el histórico. Cambio chico (1 columna + set en `checkinClient`); habilita toda la analítica de producto sobre la función que usa la mayoría. **Prioridad alta.**

## 10 · Apéndice: fórmulas y supuestos

### ▼ Erlang-B, Erlang-C y métricas M/M/c

Erlang-B (recursión):  $B(0)=1$  ;  $B(j) = a \cdot B(j-1) / (j + a \cdot B(j-1))$   
Erlang-C:  $C = B(c) / (1 - \rho \cdot (1 - B(c)))$  con  $\rho = a/c$   
 $P(\text{esperar} > 0) = C \cdot Wq = C / (c \cdot \mu - \lambda)$  ·  $W = Wq + 1/\mu$   
 $Lq = \lambda \cdot Wq$  ·  $L = \lambda \cdot W$  (Ley de Little) ·  $P(\text{espera} > t) = C \cdot e^{-(c\mu - \lambda)t}$

### ▼ Aproximación G/G/c (Allen-Cunneen)

$Wq(G/G/c) \approx Wq(M/M/c) \cdot (Ca^2 + Cs^2) / 2$   
 $Ca = 1$  (llegadas Poisson) ·  $Cs = 0.39$  (servicio real)  
factor =  $(1 + 0.39^2)/2 = 0.576$

### ▼ Distribución estacionaria (Erlang / nacimiento-muerte)

$\pi_0 = [ \sum_{n=0..c-1} a^n/n! + a^c/(c! \cdot (1-\rho)) ]^{-1}$   
 $\pi_n = a^n/n! \cdot \pi_0$  ( $n \leq c$ ) ·  $\pi_n = a^n/(c! \cdot c^{n-c}) \cdot \pi_0$  ( $n > c$ )

### ▼ Supuestos y límites

·  $\lambda(t)$  tratado por tramos (Poisson no homogéneo); los  $Wq$  son por régimen, no globales. · Servicio log-normal aproximado por Allen-Cunneen (G/G/c no tiene forma cerrada exacta). · Clientes específicos modelados como ruta dedicada; el pool aplica a dinámicos. · Sin abandono explícito (cancelación real 3–4.5 %, baja). · Datos: prod Supabase prod (gzsfoqpxvnmvngfoqqk) — consultas agregadas, ventanas 90/60 d. Sucursales de prueba excluidas.

Reproducibilidad: docs/informe/data.json (datos) · docs/informe/build\_report.py (modelo+gráficos) · docs/sim/fila\_montecarlo.py + results.json (Monte Carlo) · docs/fila-dinamica.md (spec del sistema).