

Fila Dinámica — Informe de Ingeniería

Análisis del sistema de asignación de clientes en tiempo real · teoría de colas, cadenas de Markov y validación Monte Carlo sobre datos de producción · 2026-05-16

1 · Resumen ejecutivo

La barbería es, formalmente, un **sistema de colas multi-servidor**: los clientes walk-in llegan según un proceso de **Poisson** de tasa variable $\lambda(t)$, y cada barbero es un servidor con tasa media de servicio μ . Este informe demuestra —con teoría y con datos reales— que el modelo actual (**pool dinámico no bloqueante**, mig 134) es la arquitectura **correcta y óptima** para este problema, y cuantifica por qué el modelo anterior (binding pegajoso) era subóptimo.

35.0 min

Tiempo medio de servicio

$\mu = 1.71$ cortes/h/barbero

0.93

Índice de dispersión

$\approx 1 \Rightarrow$ Llegadas Poisson (validado)

0.99

Índice de Jain (equidad)

barberos activos · 1.00 = perfecto

0.00 min

Inanición con el pool

vs 20–71 min/turno con el binding

Conclusión. Con un único pool (M/M/c) el sistema es **trabajo-conservativo** y alcanza el óptimo teórico de espera. El diseño anterior equivalía a **c filas independientes ($c \times M/M/1$)**, que el teorema de pooling demuestra estrictamente peor: hasta **16x** más espera y barberos ociosos con clientes esperando en el 71–98 % de los turnos.

2 · El modelo formal

Usamos la notación de Kendall **A/B/c**: distribución de llegadas / distribución de servicio / número de servidores. La barbería es un **M/G/c**:

- **M** (Markoviano) — llegadas Poisson, tiempos entre llegadas exponenciales y *sin memoria*. Validado en §3 (índice de dispersión 0.93).
- **G** (General) — el servicio **no** es exponencial: es **log-normal** con $CV = 0.39 \ll 1$, mucho más *regular* que la exponencial (§4).
- **c** servidores — los barberos disponibles (típico 4.9 en Rondeau, 5.8 en Paraná).

Un cliente **específico** (elige barbero) crea su propia mini-cola hacia ese servidor. Un cliente **dinámico** ("menor espera") entra a un **pool compartido** que alimenta a los **c** servidores: ese es exactamente un **M/G/c**. El cambio de mig 134 fue pasar de "c colas M/G/1 separadas" a "una cola M/G/c". La §6 prueba por qué eso importa.

```
Variables ·  $\lambda$  = tasa de llegada (clientes/h) ·  $\mu$  = 1.714 servicios/h/barbero (= 60/35.0)
a =  $\lambda/\mu$  (carga ofrecida, Erlangs) ·  $\rho$  =  $a/c = \lambda/(c \cdot \mu)$  (utilización) · estable  $\Leftrightarrow \rho < 1$ 
```

3 · Proceso de llegadas — validación de Poisson

Un proceso de Poisson tiene dos firmas comprobables en los datos: (1) el número de llegadas en intervalos fijos tiene **varianza = media** (índice de dispersión = 1), y (2) los tiempos entre llegadas son **exponenciales** (coeficiente de variación = 1). Medido sobre Rondeau, ventana operativa 10–20 h, 821 buckets de 30 min:

2.42

Media llegadas /30 min

2.25

Varianza /30 min

0.93

Índice de dispersión

Var/Media — Poisson = 1.00


1.23

CV inter-arribos

Exponencial = 1.00


Resultado. Índice de dispersión 0.93 y CV de inter-arribos 1.23: ambos ≈ 1 . Las llegadas son un **proceso de Poisson**, con la salvedad de que λ **varía con la hora** (Poisson *no homogéneo*): el modelo M/M/c se aplica por tramos horarios, no con un λ único.

Perfil real de $\lambda(t)$ — llegadas por hora, 60 días. El pico es ~18 h en ambas sucursales (Paraná 6.88/h, Rondeau 5.69/h):



4 · Proceso de servicio


Sobre 5,272 cortes (90 días): media **35.01 min**, desvío 13.67, **CV = 0.39**. Ajusta una **log-normal** ($\mu_{\log} = 3.4827$, $\sigma_{\log} = 0.3915$); la curva ajustada cae exactamente sobre los percentiles observados:



Implicación teórica clave. Como $CV_s = 0.39 < 1$, el servicio es **más regular que una exponencial** ($CV=1$). Por la aproximación de **Allen-Cunneen** para G/G/c, la espera real es $(C_a^2 + C_s^2)/2 = 0.58\times$ la que predice M/M/c. Es decir: el sistema real espera **~42 % menos** que el peor caso markoviano. Las predicciones de §5–§6 incluyen esta corrección.

Varianza por tipo de servicio


El tiempo depende fuertemente del servicio (Barba ~23 min vs Corte+Barba ~43 min). Un promedio único es un mal predictor — esto fundamenta la mejora de §9.



Servicio	n	Media	Desvío	Mediana
Corte	3073	32.7 min	±11.2	31.6 min
Corte (var.)	1774	38.0 min	±15.6	36.2 min
Corte y Barba	177	41.6 min	±12.9	40.2 min
Corte + Barba	126	43.3 min	±17.2	43.3 min
Corte + Barba (var.)	59	34.8 min	±10.6	32.7 min
Barba	40	22.6 min	±15.6	18.5 min


5 · Cadena de Markov y condición de estabilidad

El número de clientes en el sistema es una **cadena de Markov de tiempo continuo** de tipo **nacimiento-muerte**. Por la propiedad *sin memoria* de las llegadas Poisson y los servicios markovianos, el estado futuro depende solo del estado actual:



Proceso de nacimiento-muerte · nacimientos λ (Poisson) · muertes $n \cdot \mu$ ($n \leq c$) y $c \cdot \mu$ ($n > c$)

La distribución estacionaria π_n (probabilidad de tener n clientes) es la solución de equilibrio de flujo (**Erlang**). Para el escenario Rondeau-pico ($a = \lambda/\mu = 3.32$, $c = 5$, $\rho = 66\%$):



Estabilidad. El sistema es estable si y solo si $\rho = \lambda/(c \cdot \mu) < 1$ (los servidores pueden drenar la cola más rápido de lo que llega). Rondeau-pico: $\rho = 66\% < 1$ ✓ — cola finita y estacionaria. Si $\rho \rightarrow 1$ la espera crece sin techo (no lineal): por eso la capacidad (c) debe seguir a $\lambda(t)$ en horas pico.


De π_n se derivan, vía **Ley de Little ($L = \lambda \cdot W$)**, todas las métricas operativas. Verificación con datos reales de Rondeau (día completo): $\lambda \approx 3.97/h$, W observado ≈ 57 min $\Rightarrow L = \lambda \cdot W \approx 3.8$ **clientes** en el sistema en promedio — consistente con 4.9 barberos a utilización

media.

6 · Por qué el pool es la arquitectura correcta

Éste es el corazón del informe. **Teorema (pooling / "single queue")**: una única cola M/M/c con tasa total λ es **siempre** mejor (menor espera media) que c colas M/M/1 independientes con λ/c cada una. Razón: una sola cola es **trabajo-conservativa** — ningún servidor está ocioso si hay alguien esperando. c colas separadas **no** lo son: un servidor puede estar libre mientras otro acumula cola.

El binding pegajoso (mig 132/133) ataba cada dinámico a un barbero **en el check-in**: de facto, c colas M/M/1. El pool (mig 134) asigna **cuando el barbero se libera**: una cola M/M/c. Cuantificado con los parámetros reales ($\mu=1.71/h$):




Escenario	Pool M/M/c (Wq)	Pool real G/G/c	c × M/M/1 (binding)	Penalización
Rondeau pico (λ=5.69, c=5)	6.7 min	3.9 min	69 min	10.3×
Paraná pico (λ=6.88, c=6)	5.1 min	2.9 min	71 min	13.9×
c=10, ρ=0.85	12.4 min	7.1 min	198 min	16.0×

Hallazgo. Con el binding, en hora pico la espera teórica se multiplica por **10–16×** y aparecen estados imposibles bajo M/M/c: barbero ocioso + cliente esperando. La Monte Carlo (§7) confirma esto empíricamente sobre 43 200 turnos simulados.

Curva de Erlang-C (la "pared" de la congestión)

Wq crece de forma **no lineal** con ρ — es estable hasta ~80 % y explota cerca de 1. Los puntos negros son los regímenes reales medidos. Línea verde = espera real corregida por la regularidad del servicio (Allen-Cunneen).




Escenario real	λ/h	c	a (Erlang)	ρ	P(esperar)	Wq M/M/c	Wq real G/G/c	W (con servicio)
Rondeau · pico 18 h	5.69	5	3.32	66%	0.32	6.7	3.9	41.7
Rondeau · promedio día	3.97	5	2.32	46%	0.10	1.3	0.8	36.3
Paraná · pico 18 h	6.88	6	4.01	67%	0.29	5.1	2.9	40.1
Paraná · promedio día	5.33	6	3.11	52%	0.11	1.4	0.8	36.4
Caseros · promedio día	1.71	2	1.00	50%	0.33	11.6	6.7	46.6

7 · Simulación Monte Carlo

Modelo de eventos discretos calibrado con los datos reales (servicio log-normal $\mu_{\log}=3.4827$, $\sigma_{\log}=0.3915$). Grilla: barberos {3,5,7,10} × carga {0.8, 1.0, 1.15} × % dinámico {25,50,80} × popularidad {uniforme, estrella} × 5 políticas × 120 réplicas = **43 200 turnos simulados**. Reproducible en docs/sim/fila_montecarlo.py.


Políticas: **A** binding pegajoso (modelo viejo) · **B** binding con push instantáneo · **C** pool no bloqueante (modelo live, mig 134) · **D** pool + WSJF · **E** pool con gate de equidad.

El invariante duro: ningún barbero ocioso con un dinámico esperando



A ≈ B. Quitar el "push-on-complete" casi no cambia nada (la barra A ≈ B): el problema **no** era el push, era el **binding**. **C = D = 0.00**: el pool lo elimina de raíz. **E** (gate de equidad bloqueante) *reintrodujo* el problema — confirmó numéricamente que la equidad nunca debe retener trabajo.

Eficiencia y experiencia (selección de métrica)



Escenario	Inanición A→C (min/turno)	Utilización A→C	Espera P50 A→C→D (min)	Jain A / C
3 barberos	19.5 → 0.00	78.8% → 81.0%	56 → 47 → 31	0.983 / 0.975
5 barberos	38.1 → 0.00	79.6% → 81.9%	50 → 40 → 28	0.966 / 0.956
7 barberos	54.8 → 0.00	79.7% → 82.0%	45 → 35 → 25	0.951 / 0.940
10 barberos	70.8 → 0.00	79.5% → 81.7%	41 → 32 → 24	0.928 / 0.915

Throughput idéntico entre políticas a estas cargas (el turno satura): el daño del binding no es "menos cortes" sino espera, ociosidad con cola, y la promesa rota de "menor espera". El pool además sube utilización ~2 pp (≈ 0.2 barbero recuperado con 10 sillas).

8 · Auditoría de datos y patrones

Espera real por sucursal (60 días)


Sucursal	n	Media	P50	P90	P95
Parana	2591	18.7 min	9.4 min	48.4 min	60.1 min
Rondeau	1904	21.7 min	13.8 min	52.8 min	67.0 min
Caseros	768	17.7 min	5.4 min	51.1 min	68.2 min

Las esperas reales (Rondeau P50 13.8 / Paraná P50 9.4 min) son del orden que predice el modelo G/G/c corregido para carga media — el modelo **explica los datos**. Las colas P90/P95 (~50–67 min) corresponden a los picos de 17–19 h, donde $\rho \rightarrow 0.8$.


Operación por sucursal

Sucursal	Entries/día	Barberos/día	% dinámico	% cancelado	% completado
Parana	53.3	5.8	1.5%	3.1%	96.8%
Rondeau	39.7	4.9	2.3%	4.5%	95.3%
Caseros	17.1	2.0	0.6%	2.7%	96.8%

Demanda por día y hora — Rondeau



Equidad de carga — Rondeau (30 d)



Jain entre los 5 barberos activos = **0.990** ($\approx$ perfecto). El sistema reparte equitativamente; Rodri/Tony bajos = part-time/ocultos, no inequidad.

Patrones detectados. (1) Adopción de "menor espera" muy baja (0.6–2.3 %): el pool protege el sistema, pero la función está infrautilizada — gran oportunidad de producto. **(2)** Abandono bajo

(cancelado 3–4.5 %): los clientes esperan en vez de irse → la espera es un costo real de experiencia, no de ingresos perdidos (aún). **(3)** Demanda muy concentrada Jue–Sáb 17–19 h: la capacidad (c) debería escalar por franja, no ser plana. **(4)** Higiene de datos: servicios duplicados por espacios ("Corte" vs "Corte ") — distorsiona analítica por servicio; normalizar.

9 • Mejoras notables (Phase 2)

Priorizadas por impacto/esfuerzo, todas *sobre* el pool (nunca contra él):

1. **Predicción de duración por (barbero, servicio).** Hoy el panel usa un fallback de 25 min; los datos muestran 23→43 min según servicio. Una vista materializada precalculada por cron (no por tick — ver incidente 30/04) mejora el ETA y habilita lo siguiente. Impacto: estimación de espera fiable, base para WSJF.
2. **WSJF acotado por aging** en el claim del pool (política D): la Monte Carlo muestra **P50 –40 %** sin sacrificar el invariante. Como término aditivo del score, nunca como gate (lección de E / mig 129).
3. **Capacidad dinámica por franja.** $\rho \rightarrow 0.8$ sólo Jue–Sáb 17–19 h. Sugerir refuerzo en esas 6 franjas reduce el P95 sin contratar a tiempo completo.
4. **Empujar la adopción de "menor espera".** Con 0.6–2.3 % de uso, el beneficio del pool está latente; subir adopción al 30–40 % es donde el modelo M/M/c rinde su máximo (la §6 muestra el potencial 10×).

10 · Apéndice: fórmulas y supuestos

▼ Erlang-B, Erlang-C y métricas M/M/c

Erlang-B (recursión): $B(0)=1$; $B(j) = a \cdot B(j-1) / (j + a \cdot B(j-1))$
Erlang-C: $C = B(c) / (1 - \rho \cdot (1 - B(c)))$ con $\rho = a/c$
 $P(\text{esperar} > 0) = C \cdot Wq = C / (c \cdot \mu - \lambda) \cdot W = Wq + 1/\mu$
 $Lq = \lambda \cdot Wq \cdot L = \lambda \cdot W$ (Ley de Little) · $P(\text{espera} > t) = C \cdot e^{-(c\mu - \lambda)t}$

▼ Aproximación G/G/c (Allen-Cunneen)

$Wq(G/G/c) \approx Wq(M/M/c) \cdot (Ca^2 + Cs^2) / 2$
 $Ca = 1$ (llegadas Poisson) · $Cs = 0.39$ (servicio real)
factor = $(1 + 0.39^2)/2 = 0.576$

▼ Distribución estacionaria (Erlang / nacimiento-muerte)

$\pi_0 = [\sum_{n=0}^{c-1} a^n/n! + a^c/(c! \cdot (1-\rho))]^{-1}$
 $\pi_n = a^n/n! \cdot \pi_0$ ($n \leq c$) · $\pi_n = a^n/(c! \cdot c^{n-c}) \cdot \pi_0$ ($n > c$)

▼ Supuestos y límites

· $\lambda(t)$ tratado por tramos (Poisson no homogéneo); los Wq son por régimen, no globales. · Servicio log-normal aproximado por Allen-Cunneen (G/G/c no tiene forma cerrada exacta). · Clientes específicos modelados como ruta dedicada; el pool aplica a dinámicos. · Sin abandono explícito (cancelación real 3–4.5 %, baja). · Datos: prod Supabase prod (gzsfoqpxvnmvngfoqqk) — consultas agregadas, ventanas 90/60 d. Sucursales de prueba excluidas.

Reproducibilidad: docs/informe/data.json (datos) · docs/informe/build_report.py (modelo+gráficos) · docs/sim/fila_montecarlo.py + results.json (Monte Carlo) · docs/fila-dinamica.md (spec del sistema).