

MONACO SMART BARBER · INGENIERÍA · CASO REAL

Teníamos barberos **parados** mientras los clientes esperaban.

Un viernes a las 7 de la tarde: cola en la puerta y un barbero libre al lado. Lo resolvimos con **teoría de colas**, Markov y Monte Carlo sobre datos de producción.


3 sucursales

5,439 walk-ins / 60 d

3,414 clientes

43,200 turnos simulados

Un viernes a las 7 de la tarde. **Ahí** se decide todo.



En el pico la espera **típica** real se **triplica** ($P50 \approx 17$ min),
el P95 trepa a **59–70 min** y el peor caso a **139 min**. En

El sistema "reservaba" cada cliente a un barbero **al llegar**.

De facto, no era **una fila para todos**: eran **c filas separadas**, una por barbero. Si tu barbero asignado se complicaba, esperabas — aunque otro estuviera libre y no pudiera atenderte.

✗ **Binding al check-in**

c × fila individual

✓ **Pool al liberarse**


1 fila · c servidores

NO ERA UN CASO DE BORDE

≈ **47%** de los clientes elige
"el que esté libre".

El bug degradaba a **la mayoría**, no a un nicho. Y fuimos honestos con los datos: **detectamos y corregimos un error en nuestra propia métrica** que subestimaba esa adopción (un flag que se reseteaba al asignar). La rigurosidad también es revisar lo propio.

Una sola fila para todos es siempre mejor que c filas.



Mismos barberos, misma demanda — solo cambia la

arquitectura: **10x menos espera** en el pico. Y valida con

la realidad: el modelo viejo (c x M/M/1) predice **63–117**

con clientes **esperando**.

Ojo: esto NO es el tiempo de espera (esa es la slide anterior, y en el pico no es cero). Esto es el **desperdicio**: minutos por turno con un barbero **libre** mientras alguien esperaba — y ocurre a **cualquier carga**, no sólo en el pico. Viejo: hasta 71 min/turno. Pool: **0** (por diseño: trabajo-conservativo).



Mejor para el cliente **y** para el negocio.

0.00

min de desperdicio
barbero libre + cola · antes 20–71

–44%

tiempo de espera P50
baja — no llega a cero

+2 pp

utilización
≈ 0.2 barbero/10 sillas

0.96–1.00

equidad (Jain)
carga pareja entre barberos

La espera **baja** —no se elimina: en un pico sigue habiendo cola y se espera—, pero deja de haber **sillas vacías con gente esperando**. Validado además contra datos reales con **Erlang-C** y **Allen-Cunneen** (G/G/c).

Lo que nos llevamos.

- 1 Asigná cuando el recurso se libera**, no cuando el trabajo llega. La asignación temprana destruye la conservación de trabajo.
- 2 La equidad nunca debe retener trabajo.** Un "gate de justicia" que deja a alguien parado reintroduce el problema (lo probamos).
- 3 Validá con teoría + simulación + datos**, no con intuición. Los tres coincidieron.
- 4 Medí dos veces.** Corregimos nuestro propio error de métrica antes de sacar conclusiones.

MONACO SMART BARBER

Construimos software de gestión para barberías con **esta** vara.

Teoría de colas (M/G/c, Erlang), cadenas de Markov, Ley de Little y Monte Carlo — aplicados a un problema real de operación, no a una slide.

— Equipo de Plataforma · 2026-05-16