

MONACO SMART BARBER · INGENIERÍA · CASO REAL

Teníamos barberos **parados** mientras los clientes esperaban.

Un viernes a las 7 de la tarde: cola en la puerta y un barbero libre al lado. Lo resolvimos con **teoría de colas**, Markov y Monte Carlo sobre datos de producción.

3 sucursales

5,439 walk-ins / 60 d

3,414 clientes

43,200 turnos simulados

Un viernes a las 7 de la tarde. **Ahí** se decide todo.



Espera típica real (mediana) · día tranquilo vs pico (Jue–Sáb 16–20 h)

La espera **típica** se **triplica** en el pico ($P50 \approx 17$ min); $P95$ **59–70 min**, peor caso **139 min**. En valle casi da igual el modelo: **el retorno de la mejora vive en el pico**.

LA CAUSA RAÍZ

El sistema "reservaba" cada cliente a un barbero **al llegar**.

De facto, no era **una fila para todos**: eran **c filas separadas**, una por barbero. Si tu barbero asignado se complicaba, esperabas — aunque otro estuviera libre y no pudiera atenderte.

✗ Binding al check-in

c × fila individual

✓ Pool al liberarse

1 fila · c servidores

NO ERA UN CASO DE BORDE

≈ **47%** de los clientes elige
"el que esté libre".

El bug degradaba a **la mayoría**, no a un nicho. Y fuimos honestos con los datos: **detectamos y corregimos un error en nuestra propia métrica** que subestimaba esa adopción (un flag que se reseteaba al asignar). La rigurosidad también es revisar lo propio.

Una sola fila para c barberos es **siempre** mejor que c filas.




Misma gente, misma demanda — solo cambia la arquitectura: **10x menos espera** en el pico. El modelo viejo predice **63–117 min**; el P95 real del pico es **59–70 min. Coinciden.**

Cero barberos parados con clientes esperando.

Ojo: esto NO es el tiempo de espera (esa es la slide anterior, y en el pico no es cero). Esto es el desperdicio: minutos por turno con un barbero libre mientras alguien esperaba — y ocurre a cualquier carga, no sólo en el pico. Viejo: hasta 71 min/turno. Pool: 0 (por diseño: trabajo-conservativo).



En el pico, la espera se desploma.



Espera mediana simulada · régimen saturado ($\rho \geq 1$) · misma carga y capacidad · por nº de barberos

La comparativa que importa en **alta demanda**: binding (viejo) deja P50 **56–72 min**; el pool (nuevo, ya en producción) **44–61 min**; con WSJF (Phase 2) **31–38 min**. Misma gente, misma demanda — solo cambia el modelo.

EL IMPACTO

Mejor para el cliente **y** para el negocio.

0.00

min de desperdicio
barbero libre + cola · antes 20–71

–44%

tiempo de espera P50
baja — no llega a cero

+2 pp

utilización
≈ 0.2 barbero/10 sillas

0.96–1.00

equidad (Jain)
carga pareja entre barberos

La espera **baja** —no se elimina: en un pico sigue habiendo cola y se espera—, pero deja de haber **sillas vacías con gente esperando**.
Validado además contra datos reales con **Erlang-C** y **Allen-Cunneen** (G/G/c).

Lo que nos llevamos.

- 1** **Asigná cuando el recurso se libera**, no cuando el trabajo llega. La asignación temprana destruye la conservación de trabajo.
- 2** **La equidad nunca debe retener trabajo.** Un "gate de justicia" que deja a alguien parado reintroduce el problema (lo probamos).
- 3** **Validá con teoría + simulación + datos**, no con intuición. Los tres coincidieron.
- 4** **Medí dos veces.** Corregimos nuestro propio error de métrica antes de sacar conclusiones.

MONACO SMART BARBER

Construimos software de gestión para barberías con **esta** vara.

Teoría de colas (M/G/c, Erlang), cadenas de Markov, Ley de Little y Monte Carlo — aplicados a un problema real de operación, no a una slide.

— Equipo de Plataforma · 2026-05-16